

Módulo 8. Aplicaciones de inteligencia artificial en áreas funcionales (2h)

FICHA 8.1 – IA en Marketing y Ventas: segmentación, personalización, recomendación y propensión

Referencia

- **Módulo:** 8. Aplicaciones de IA en áreas funcionales (12 h)
- **Apartado:** 8.1. IA en Marketing y Ventas
- **Capítulo:** 8.1.1–8.1.2

Palabras clave

segmentación con IA, personalización, sistemas de recomendación, propensión, lead scoring, next best action, churn, CAC, LTV, ROAS, atribución, uplift, A/B test, sesgo, privacidad, consentimiento, gobernanza marketing data.

Objetivos de aprendizaje

Al finalizar esta ficha, deberás ser capaz de:

1. Diferenciar con precisión **segmentación, personalización, recomendación y modelos de propensión** (y saber cuándo conviene cada enfoque).
2. Traducir un objetivo genérico (“usar IA en marketing”) a **decisiones concretas** (entrada → criterio → salida) y a su impacto esperado.
3. Identificar los **datos mínimos** y sus riesgos (privacidad, consentimiento, calidad, sesgos) para construir casos realistas en empresa.
4. Definir métricas correctas (no vanidad) para evaluar impacto: CTR/CVR/CPA/ROAS, pero sobre todo **CAC/LTV/retención/uplift**.
5. Describir controles básicos: **revisión humana**, límites de uso, auditoría por segmentos y buenas prácticas de cumplimiento.

Síntesis

La IA en marketing y ventas se aplica sobre todo a mejorar decisiones repetitivas: **a quién impactar, con qué promesa, por qué canal y en qué momento**. Para dominarla, necesitas comprender los conceptos nucleares (segmentación, personalización, recomendación, propensión), conectarlos con datos mínimos, medir con KPIs adecuados y aplicar controles para reducir riesgos (sesgo, privacidad, reputación y atribución engañosa).

Contenido principal

1) IA en marketing como disciplina de decisión

Cuando un equipo dice “queremos usar IA en marketing”, muchas veces piensa en producir más contenido o automatizar campañas. Sin embargo, el núcleo profesional de la IA en marketing/ventas es **mejorar decisiones** que se repiten a gran escala y tienen impacto económico. La IA aporta valor cuando reduce el “desperdicio” (impactar a quien no interesa, enviar mensajes irrelevantes, invertir en leads con baja probabilidad) y cuando aumenta consistencia en mensajes y procesos.

Para que un caso de uso sea sólido, debe poder explicarse con esta frase (y poder medirse):

1. **Decisión** que queremos mejorar
2. **Señales/datos** que usaremos (mínimos, legítimos)
3. **Salida/acción** que activará el sistema
4. **KPI** que medirá éxito (con umbral)
5. **Riesgos y controles** (privacidad, sesgo, revisión humana)

Si no puedes completar estos cinco elementos, todavía no es un caso de uso; es una intención.

2) Los cuatro conceptos clave (y cómo no confundirlos)

2.1 Segmentación

La **segmentación** agrupa personas en conjuntos relativamente homogéneos para tratarlas de forma distinta. Su valor aparece cuando cada segmento implica una **decisión operable**: un mensaje diferente, una oferta distinta, un canal diferente o una prioridad distinta.

- **Segmentación por reglas (clásica)**: “si abrió 2 emails y visitó pricing → segmento tibio”.
- **Segmentación con IA (descubrimiento de patrones)**: clustering o modelos que detectan grupos no obvios.

Ventajas: suele ser más explicable y fácil de operar que la personalización individual; funciona bien como primer paso.

Riesgo típico: segmentar con variables que actúan como *proxy* (p. ej., ciertas zonas/estudios) y terminar discriminando sin querer.

2.2 Personalización

La **personalización** adapta contenido/experiencia a un usuario o microsegmento. No tiene por qué ser “hiperpersonal” ni usar datos intrusivos; muchas personalizaciones rentables son contextuales:

- por **etapa del funnel** (descubrimiento vs decisión),
- por **intención** (comparar vs comprar),
- por **objeción** (precio, confianza, complejidad),
- por **comportamiento reciente** (visitó pricing, descargó guía).

Riesgos típicos: sensación de invasión (“creepy”), uso de datos no consentidos, incoherencia de marca y promesas no verificables (“claims”).

Control recomendado: guía de tono + lista de claims permitidos + revisión humana en campañas sensibles.

2.3 Recomendación

La **recomendación** decide qué productos/contenidos mostrar primero y en qué orden. Es un problema de **priorización**: el orden importa porque guía la atención y, por tanto, la conversión.

- Enfoques frecuentes: reglas (“si compra X, sugiere Y”), similitud (“usuarios similares...”), modelos combinados.
- Problemas típicos: **cold start** (poca info de usuario o producto nuevo) y “burbuja” (recomendar siempre lo mismo).

Controles útiles: reglas de negocio (no recomendar sin stock), diversidad (mezclar complementarios y alternativos) y medición downstream (no solo clics).

2.4 Propensión

La **propensión** es un score de probabilidad de que ocurra algo (comprar, convertir, abandonar, responder). En marketing/ventas se usa para:

- **lead scoring** (a quién llama ventas),
- **next best action** (qué acción maximiza avance),
- **retención** (quién está en riesgo de churn).

Un error frecuente es tratar el score como “verdad”. En realidad, es una probabilidad condicionada por señales actuales. Por eso debe usarse para **priorizar intervención**, no para automatizar decisiones críticas sin supervisión.

3) Plantilla para bajar a tierra un caso de uso

Para dominar el tema, acostúmbrate a formular cualquier caso con esta plantilla:

1. **Nombre del caso** (breve)
2. **Decisión:** ¿qué cambia?
3. **Usuario/rol:** ¿quién lo usa?
4. **Inputs/señales:** ¿qué datos mínimos?
5. **Output/acción:** ¿qué se genera o decide?
6. **KPI + umbral:** ¿qué es éxito?
7. **Riesgos:** sesgo, privacidad, reputación, calidad
8. **Controles:** revisión humana, reglas, auditoría, registro

Ejemplo (lead scoring básico):

Decisión: priorizar llamadas. Inputs: fuente, páginas clave visitadas, interacción email, tamaño empresa. Output: score + razones + acción sugerida. KPI: tasa de demo y conversión a oportunidad. Control: auditoría por segmentos, grupo control periódico, variables sensibles prohibidas.

4) Datos mínimos y calidad: lo que limita el proyecto (más que el modelo)

En marketing y ventas, “tener datos” no significa poder usarlos. El éxito depende de **consistencia y trazabilidad**, especialmente entre CRM, analytics, campañas y soporte.

Fuentes típicas (primer nivel):

Programa Superior en Inteligencia Artificial Aplicada a la Empresa

Fichas de contenido

- CRM (leads, etapa, sector, actividad comercial)
- Web/app analytics (eventos, páginas, funnels)
- Email marketing (aperturas, clics, bajas)
- E-commerce (compras, carrito, devoluciones)
- Soporte (tickets, motivos, satisfacción)
- Ads (costes, audiencias, conversiones)

Errores de calidad típicos:

- CRM desactualizado o etapas mal definidas
- duplicados y campos inconsistentes
- UTM's mal usadas → atribución confusa
- eventos mal implementados → funnel roto
- cambios en tracking sin documentación

Buenas prácticas mínimas (muy “de puesto de trabajo”):

- diccionario de datos (qué significa cada campo)
- convenciones de nomenclatura (campañas/eventos)
- minimización (usar lo necesario)
- lista de datos prohibidos o delicados
- registro de cambios (cuando se altera el tracking o la lógica)

5) Medición: de métricas de canal a métricas de negocio (y el papel del uplift)

Para evaluar IA en marketing no basta con métricas “rápidas”. Debes separar capas:

Métricas de canal (útiles pero insuficientes):

- CTR, CPC, CPM, aperturas, engagement

Métricas de conversión:

- CVR, CPA, ROAS, tasa de lead cualificado

Métricas de negocio (las que mandan):

- CAC, LTV, retención/churn, margen

Cuando personalizas o recomiendas, necesitas saber si la mejora se debe a la IA o a factores externos. Aquí entra el **uplift**: la mejora atribuible a la intervención. La forma más práctica de aproximarla es:

- **A/B test** (grupo control vs grupo personalizado)
- **holdout** (un % no recibe intervención para comparar)

Sin control (aunque sea mínimo), es fácil autoengañarse: creer que la IA “funciona” cuando solo coincide con una campaña mejor, un cambio de temporada o una tendencia externa.

6) Riesgos y controles: cómo hacerlo defendible en empresa

En marketing/ventas, los riesgos más frecuentes son operativos y reputacionales:

Riesgos principales:

1. Sesgo (tratamiento desigual por proxies)
2. Privacidad/consentimiento (uso indebido de datos)
3. Sobrepersonalización (sensación intrusiva)

4. Atribución engañosa (optimizar métrica equivocada)
5. Brand risk (tono incoherente, claims inventados)
6. Alucinaciones (si se usa un LLM para copy sin control)

Controles mínimos recomendados:

- checklist de claims (“si no está verificado, no se afirma”)
- formato y guías de tono (consistencia de marca)
- revisión humana para outputs externos críticos
- auditoría por segmentos (mirar resultados por grupos, no solo global)
- registro/versionado (prompts, reglas y cambios de tracking)
- reglas de datos (permitidos/prohibidos) y anonimización cuando proceda

7) Herramientas IA y recursos útiles (en un puesto junior)

La mayoría de equipos extraen gran parte del valor combinando **buen criterio + datos correctos + medición + un LLM**.

LLMs (trabajo diario): ChatGPT / Claude / Gemini / Copilot

- briefs, variantes de copy, resumen de feedback, clusterización de temas, propuestas de segmentación, hipótesis CRO.

SEO/SEM y research: Google Trends, Search Console, Semrush/Ahrefs

- intención, oportunidades, performance orgánico/pago.

Creatividades: Canva / Adobe Express (equivalentes)

- adaptaciones de assets, variantes por formato.

Medición y comportamiento: GA4 / Looker Studio / Microsoft Clarity o Hotjar

- funnels, fricciones, dashboards.

CRM & automatización: HubSpot / Mailchimp / ActiveCampaign / Brevo

- nurturing, segmentación, lead scoring por reglas (y evolución posterior).

8) Mini-glosario (para dominar vocabulario)

- **Segmentación:** agrupar audiencias para decisiones distintas.
- **Personalización:** adaptar mensaje/experiencia a usuario o microsegmento.
- **Recomendación:** ordenar opciones para maximizar un objetivo.
- **Propensión:** probabilidad de conversión/compra/churn.
- **CAC/LTV:** coste de adquirir vs valor total del cliente.
- **Uplift:** mejora atribuible a la intervención (control vs tratado).
- **Holdout:** grupo sin intervención para comparar.

Relación de ideas clave

- IA útil en marketing = **mejorar una decisión medible**.
- Segmentación/personalización/recomendación/propensión son conceptos distintos con riesgos y mediciones distintas.
- CAC/LTV/retención mandan sobre métricas de vanidad.
- Uplift y control evitan conclusiones falsas.

- Privacidad, sesgo y claims son los riesgos principales; se controlan con políticas, revisión humana y auditoría.

Más información en ChatGPT

1. “Con este negocio: [sector, producto, cliente ideal], propón 6 casos de IA en marketing/ventas. Para cada uno: decisión, datos mínimos, KPI, riesgo y control.”
2. “Ayúdame a diseñar un lead scoring: variables permitidas, variables prohibidas, explicación del score y plan de validación con control.”
3. “Dame un checklist de control de calidad para copy generado por IA en campañas (claims, tono, cumplimiento, CTA, coherencia con landing).”

FICHA 8.2 — IA en Logística y Cadena de Suministro: demanda, inventario, rutas y mantenimiento predictivo

Referencia

- **Módulo:** 8. Aplicaciones de IA en áreas funcionales (12 h)
- **Apartado:** 8.2. IA en Logística y Cadena de Suministro
- **Capítulo:** 8.2.1–8.2.2

Palabras clave

predicción de demanda, forecasting, estacionalidad, lead time, nivel de servicio, rotura de stock, stock de seguridad, inventario, optimización de rutas, ventanas horarias, restricciones, coste logístico, OTIF, fill rate, MRP, mantenimiento predictivo, condition monitoring, anomalías, alertas operativas.

Objetivos de aprendizaje

Al finalizar esta ficha, deberás ser capaz de:

1. Diferenciar **predicción** (anticipar demanda/fallos) de **optimización** (decidir inventario/rutas) y entender por qué se complementan.
2. Traducir un objetivo genérico (“mejorar logística con IA”) a **decisiones operativas concretas** (qué se decide, con qué datos y con qué salida).
3. Identificar **datos mínimos** por caso (demanda, inventario, transporte, mantenimiento) y riesgos asociados (calidad, sesgos de dato, excepciones).
4. Definir KPIs operativos correctos (OTIF, fill rate, roturas, coste, puntualidad, downtime) y comprender el **coste del error** (sobrestock vs rotura, retraso vs coste).
5. Describir controles básicos: rutas de excepción, supervisión humana, trazabilidad y monitorización (deriva/estacionalidad/cambios operativos).

Síntesis

La IA en logística y supply chain aporta valor cuando convierte señales (ventas, stock, plazos, incidencias, sensores) en decisiones operables: cuánto reponer, cuándo pedir, cómo distribuir inventario, qué ruta ejecutar o cuándo intervenir una máquina antes de que falle. El éxito no depende solo de predecir, sino de diseñar el circuito completo: datos → decisión → acción → medición, con reglas de negocio, gestión de excepciones y control del riesgo.

Contenido principal

1) La cadena de suministro como “sistema de decisiones”

En logística, casi todo es una decisión bajo restricciones. Se decide **qué** comprar o producir, **cuánto**, **cuándo**, **dónde** almacenarlo, **cómo** moverlo y **qué priorizar** cuando no se puede cumplir todo. La IA entra como un “motor de soporte” que reduce incertidumbre (predicción) y ayuda a elegir mejor bajo restricciones (optimización). Para dominar el tema, no hay que memorizar modelos matemáticos; hay que aprender a formular problemas logísticos como decisiones medibles.

Una forma útil de enmarcar cualquier caso de IA en supply chain es la misma que en marketing:

1. **Decisión:** ¿qué se decide exactamente? (reponer, planificar, enrutar, intervenir mantenimiento)
2. **Señales:** ¿con qué datos se toma esa decisión?
3. **Salida/acción:** ¿qué cambia en la operación? (orden de compra, stock objetivo, ruta, prioridad, alerta)
4. **KPI:** ¿cómo sabremos que mejoró?
5. **Riesgos/controles:** ¿qué puede fallar y cómo se gestiona?

En logística, una predicción sin acción es solo un informe. La IA solo aporta cuando se conecta a una acción operativa.

2) Predicción vs optimización: dos piezas que se confunden

En conversaciones no técnicas es común llamar “predicción” a todo. En realidad, conviene diferenciar:

- **Predicción (forecasting / detección):** estima un valor futuro o detecta una condición probable. Ejemplos: demanda esperada por producto, probabilidad de rotura de stock, probabilidad de fallo de una máquina, ETA (hora estimada de llegada).
- **Optimización (decisión bajo restricciones):** elige la mejor acción posible dado un objetivo y restricciones. Ejemplos: cuánto stock de seguridad mantener, cómo repartir inventario entre almacenes, qué ruta asignar a qué vehículo, qué pedidos priorizar.

La predicción reduce incertidumbre; la optimización decide qué hacer con esa información. Cuando la predicción mejora, no siempre mejora el negocio si la decisión no

está bien definida. Del mismo modo, una optimización excelente con datos malos puede llevar a decisiones “perfectas” sobre una realidad incorrecta.

3) Predicción de demanda: qué significa “prever” en la práctica

La predicción de demanda intenta anticipar cuánto se venderá o consumirá en un horizonte (día/semana/mes) para poder planificar compras, producción e inventario. En la práctica, la demanda no es un número único: varía por producto, canal, región y temporada, y está afectada por promociones, cambios de precio, roturas anteriores y tendencias.

Decisiones que habilita:

- qué cantidad pedir (orden de compra)
- cuándo pedir (punto de pedido)
- qué stock mantener (stock objetivo/seguridad)
- cómo distribuir por almacenes

Variables típicas (señales):

- histórico de ventas y devoluciones
- estacionalidad (día de la semana, mes, campañas)
- promociones, precio, disponibilidad
- lead times (plazos) y restricciones de proveedor
- eventos externos (si son relevantes y medibles)

Riesgo clásico: confundir “precisión media” con “impacto”. En supply chain, lo que importa no es solo acertar el número, sino minimizar el coste total: sobrestock (capital inmovilizado, obsolescencia) y rotura (pérdida de ventas, penalizaciones, insatisfacción).

4) Inventario: stock de seguridad, nivel de servicio y coste del error

El inventario es el colchón que absorbe incertidumbre. Sin inventario, cualquier variación en demanda o plazos rompe el servicio. Con demasiado inventario, el negocio pierde dinero por capital inmovilizado, almacenamiento, caducidad u obsolescencia.

Para entender inventario con IA, hay que dominar tres conceptos:

a) Lead time: el tiempo entre pedir y recibir. Si el lead time es variable, el riesgo de rotura aumenta.

b) Nivel de servicio: qué probabilidad quieres de no quedarte sin stock. No es un “sí/no”; es una decisión.

c) Stock de seguridad: cantidad extra para cubrir variabilidad de demanda y de plazos.

Decisión central: dónde colocar el equilibrio entre coste y servicio. Una empresa puede elegir un servicio del 95% y aceptar roturas ocasionales, o exigir 99% en productos críticos. La IA ayuda a ajustar stock por producto y contexto, pero el negocio define el umbral aceptable.

KPIs típicos:

- **Roturas de stock** (stockouts)
- **Fill rate** (porcentaje de demanda satisfecha)
- **Nivel de servicio** (probabilidad de disponibilidad)

- **Inventario medio y días de inventario**
- **Coste de almacenamiento y obsolescencia**

5) Optimización de rutas: objetivos, restricciones y trade-offs

La optimización de rutas es un clásico porque el coste del transporte suele ser relevante y las restricciones son numerosas. El objetivo puede ser minimizar coste, tiempo o kilómetros, pero casi siempre hay un equilibrio entre objetivos.

Restricciones típicas (las que mandan de verdad):

- capacidad del vehículo (peso/volumen)
- ventanas horarias (entregas solo 9–12)
- prioridad del cliente (SLA)
- tiempos de carga/descarga
- limitaciones de conductor y turnos
- restricciones geográficas o tráfico

Decisiones que habilita:

- qué pedidos agrupar en un vehículo
- orden de paradas
- asignación de rutas por día
- replanificación ante incidencias

Riesgo clásico: optimizar un objetivo equivocado. Por ejemplo, minimizar kilómetros puede aumentar retrasos; minimizar tiempo puede aumentar costes. Por eso la optimización debe estar ligada a KPIs y a una política de negocio (qué es “lo más importante” y cuándo se permite romper un objetivo).

KPIs típicos de transporte:

- puntualidad y OTIF (On Time In Full)
- coste por entrega / km / pedido
- tiempo de ruta y utilización de capacidad
- incidencias y reentregas

6) Mantenimiento predictivo: de “fallo” a “intervención”

El mantenimiento predictivo se basa en anticipar fallos o degradaciones para intervenir antes de que haya una parada costosa. En la práctica, muchas empresas no necesitan modelos sofisticados para empezar; pueden iniciar con detección de anomalías y reglas de umbral sobre señales.

Decisiones que habilita:

- cuándo parar para mantenimiento (planificado vs reactivo)
- qué máquina priorizar
- qué repuestos preparar
- qué condiciones disparan una inspección

Señales típicas:

- vibración, temperatura, consumo, presión
- histórico de incidencias y horas de uso

- condiciones de operación (turnos, carga)

KPIs típicos:

- downtime (tiempo de parada)
- MTBF (tiempo medio entre fallos)
- MTTR (tiempo medio de reparación)
- costes de mantenimiento y repuestos
- % mantenimiento correctivo vs preventivo

Riesgo clásico: alertas excesivas (fatiga de alertas). Si el sistema dispara demasiadas alertas, la operación lo ignorará. Por eso es imprescindible definir umbrales, priorización y circuito de revisión.

7) Datos mínimos y calidad: por qué supply chain es sensible a “datos rotos”

En logística, un dato erróneo se convierte en una decisión errónea y esa decisión se convierte en un coste. Por eso, además de saber “qué datos”, hay que entender “qué calidad” se requiere y dónde se rompe el dato.

Fuentes típicas:

- ERP/MRP (compras, producción, stocks, órdenes)
- WMS (almacén)
- TMS (transporte)
- POS/e-commerce (ventas)
- incidencias/atención al cliente
- sensores/SCADA (mantenimiento)

Errores frecuentes:

- lead times mal registrados (promedio irreal)
- stocks inexactos (inventario “teórico” $\neq$ real)
- devoluciones no imputadas correctamente
- incidencias sin codificación homogénea
- cambios de catálogo (SKU) sin trazabilidad histórica

Buenas prácticas mínimas:

- diccionario de datos y definiciones de KPIs
- registro de cambios de procesos (si cambia cómo se repone, cambia el dato)
- control de duplicados y de unidades
- validaciones de entrada/salida (no permitir valores imposibles)

8) Operación: del modelo al trabajo diario (alertas, excepciones y ownership)

Un proyecto de IA en logística fracasa cuando se queda en “dashboard bonito” sin operación. Para que sea real, debe definirse un circuito operativo:

1. **Señal:** forecast/alerta/sugerencia (p. ej., “riesgo de rotura en 7 días”).
2. **Regla de decisión:** umbral y prioridad (p. ej., “si riesgo > X y producto crítico → actuar”).
3. **Acción:** orden de compra, transferencia, replanificación, intervención.
4. **Responsable (owner):** quién decide y ejecuta.

5. **Registro:** qué se hizo y por qué (trazabilidad).

6. **Revisión:** cadencia semanal/mensual para ajustar umbrales y reglas.

Gestión de excepciones: siempre habrá casos raros: un proveedor cambia plazos, una promoción dispara demanda, un vehículo se avería. Por eso el diseño debe incluir rutas de excepción y supervisión humana.

9) Medición: KPIs “de verdad” y el coste del error

La medición en supply chain no se resume en “precisión del modelo”. El objetivo es optimizar una función de coste y servicio.

KPIs recomendados por dominio:

- Demanda/inventario: roturas, fill rate, inventario medio, obsolescencia, nivel de servicio
- Transporte: OTIF, coste por entrega, puntualidad, incidencias
- Mantenimiento: downtime, MTBF, MTTR, % correctivo, coste de repuestos

Coste del error (ejemplos):

- Prever de menos → rotura y pérdida de ventas + penalización + insatisfacción
- Prever de más → sobrestock y capital inmovilizado + obsolescencia
- Ruta mal optimizada → retrasos y reentregas + coste extra
- Alerta falsa de mantenimiento → parada innecesaria
- No detectar un fallo → parada crítica

Comprender este coste es lo que permite elegir umbrales, priorizar acciones y justificar la inversión.

10) Herramientas y recursos útiles (orientado a puesto junior)

En un rol junior, es más importante dominar el flujo de decisión y KPIs que instalar software avanzado. Aun así, hay herramientas típicas que conviene conocer por categorías:

- **Datos/ERP/WMS/TMS:** SAP, Dynamics, Odoo (según empresa), soluciones WMS/TMS locales.
- **Analítica y reporting:** Excel/Sheets, Power BI, Looker Studio.
- **Optimización y rutas (operativo):** herramientas de route planning (según sector) + TMS; en pymes, soluciones SaaS específicas de reparto.
- **Mantenimiento:** CMMS (sistemas de mantenimiento) + cuadros de mando básicos; en industria, plataformas de monitorización.
- **IA/LLMs (apoyo):** ChatGPT/Claude/Gemini para documentar procesos, generar plantillas, clasificar incidencias y construir checklists (siempre con datos anonimizados).

Consejo práctico: en supply chain, un “MVP” valioso puede ser una tabla de alertas operables con criterios claros, aunque el modelo sea simple.

11) Mini-glosario

- **Lead time:** tiempo entre pedir y recibir.

Programa Superior en Inteligencia Artificial Aplicada a la Empresa

Fichas de contenido

- **Fill rate:** % de demanda satisfecha.
- **OTIF:** entregado a tiempo y completo.
- **Stock de seguridad:** colchón para variabilidad.
- **Optimización:** elegir la mejor acción bajo restricciones.
- **Anomalía:** señal fuera de patrón normal.
- **MTBF/MTTR:** métricas de fiabilidad y reparación.

Relación de ideas clave

- Predicción y optimización son distintas: la primera anticipa; la segunda decide.
- La IA solo aporta cuando se conecta a una acción operativa con owner y registro.
- Las restricciones mandan (capacidad, ventanas, lead times).
- Los KPIs deben reflejar coste del error (rotura vs sobrestock, retraso vs coste).
- Alertas sin circuito operativo generan fatiga y se ignoran.

Más información en ChatGPT

1. “Propón 5 casos de IA en logística para una empresa de [sector]. Para cada caso: decisión, datos mínimos, KPI, riesgos y controles.”
2. “Ayúdame a definir un sistema de alertas de rotura de stock: umbrales, prioridad, quién actúa, y cómo medir impacto.”
3. “Explícame la diferencia entre forecasting y optimización con un ejemplo de inventario y rutas, incluyendo trade-offs.”

FICHA 8.3 — IA en Recursos Humanos: selección/movilidad, rotación/clima y formación personalizada (con equidad, privacidad y supervisión humana)

Referencia

- **Módulo:** 8. Aplicaciones de IA en áreas funcionales (12 h)
- **Apartado:** 8.3. IA en Recursos Humanos
- **Capítulo:** 8.3.1–8.3.2

Palabras clave

IA en RRHH, reclutamiento asistido, matching de candidatos, screening CV, variables proxy, sesgo en selección, equidad, transparencia, privacidad RRHH, datos sensibles, clima laboral, análisis de sentimiento, rotación, predicción de churn, formación personalizada, upskilling, supervisión humana, trazabilidad de decisiones.

Objetivos de aprendizaje

Al finalizar esta ficha, deberás ser capaz de:

1. Diferenciar **asistencia** vs **decisión automática** en RRHH y comprender por qué es un punto crítico legal, ético y reputacional.
2. Traducir casos de IA en RRHH a **decisiones operativas concretas** (qué se decide, con qué señales, qué salida/acción produce).
3. Identificar datos **razonables** vs datos **sensibles** y aplicar principios de minimización, finalidad y transparencia en proyectos de RRHH.
4. Reconocer riesgos de **sesgo** y **variables proxy**, y proponer controles básicos (supervisión humana, auditoría por grupos, explicaciones y documentación).
5. Definir KPIs útiles y límites de uso para casos típicos (selección, rotación/clima, formación) y diseñar un circuito de operación seguro.

Síntesis

RRHH es un área con gran potencial de IA (eficiencia, mejor información para decisiones, personalización de formación), pero también es un área de **alto riesgo**: se trabaja con datos personales y decisiones que afectan directamente a las personas. Por eso, los proyectos de IA en RRHH deben diseñarse como sistemas de **apoyo** y no como “jueces automáticos”, incorporando supervisión humana, transparencia, minimización de datos, controles contra sesgo y trazabilidad.

Contenido principal

1) RRHH como “sistema de decisiones” (y por qué la IA es más sensible aquí)

RRHH no es solo administración; es el conjunto de decisiones que determinan quién entra, cómo se desarrolla, cómo se evalúa y cómo se retiene el talento. Estas decisiones tienen impacto sobre la vida profesional de las personas y sobre la cultura y reputación de la organización. Por ello, aplicar IA en RRHH exige un estándar más alto de cuidado: no basta con que el sistema sea eficiente; debe ser **justo, explicable, y respetuoso con privacidad y derechos**.

Desde el punto de vista práctico, la IA en RRHH se justifica cuando mejora decisiones repetitivas o procesos informacionales, por ejemplo: ordenar candidaturas, detectar habilidades faltantes, sugerir itinerarios formativos, resumir feedback, identificar patrones agregados en encuestas o tickets internos. Sin embargo, cualquier uso que se acerque a “decidir” automáticamente (descartar candidatos, recomendar despidos, asignar penalizaciones) aumenta enormemente el riesgo y suele requerir controles estrictos y una base de cumplimiento robusta.

Una idea que conviene interiorizar: en RRHH, la IA suele ser más útil como **asistente** que acelera y estructura información, y como **sistema de alerta** que sugiere dónde mirar, no como motor que reemplaza el juicio humano.

2) El principio rector: asistencia vs decisión automática

Para diseñar casos de IA en RRHH de forma segura, lo primero es clasificar el uso en uno de estos niveles:

1. **Asistencia informacional:** resume, clasifica, extrae, organiza. Ejemplo: resumir CVs, extraer habilidades, crear fichas comparativas, redactar emails o documentación.
2. **Recomendación supervisada:** sugiere una acción o priorización, pero siempre con revisión humana. Ejemplo: “priorizar entrevistas” o “sugerir itinerarios formativos” con explicación.
3. **Decisión automática (alto riesgo):** decide o ejecuta una consecuencia directa sin intervención humana significativa. Ejemplo: descartar automáticamente por score o activar consecuencias disciplinarias.

En la práctica, los proyectos académicos y la mayoría de implantaciones responsables en empresa se mueven en los niveles 1 y 2. El nivel 3 requiere análisis legal y de riesgos mucho más serio, además de documentación y auditoría constante.

3) Los tres grandes dominios de uso en RRHH (y qué decisión habilitan)

3.1 Selección y movilidad interna (reclutamiento asistido)

En selección, la IA se usa para gestionar volumen y estandarizar criterios. Las decisiones típicas que habilita son: priorizar candidatos para entrevista, estructurar comparativas, detectar habilidades alineadas con el puesto o identificar información faltante.

- **Inputs habituales:** CVs, descripciones de puesto, formularios de candidatura, notas de entrevista, portfolio.
- **Outputs útiles:** resumen estructurado del CV, matriz de ajuste a requisitos, preguntas sugeridas para entrevista, checklist de evidencias.

Aquí es crucial separar “matching de habilidades” (útil) de “score opaco” (arriesgado). Una recomendación responsable es usar la IA para **estructurar** la información y que la decisión final sea humana, con criterios explícitos.

3.2 Rotación, clima y bienestar (analítica de personas con límites)

En rotación y clima, la IA puede detectar patrones agregados: temas recurrentes en encuestas, señales de riesgo en ciertos equipos o momentos, y sugerir intervenciones (formación, cambios de proceso, revisión de carga).

- **Inputs habituales:** encuestas de clima, feedback 1:1 (si está permitido), indicadores de absentismo agregados, datos de movilidad, datos de desempeño agregados.
- **Outputs útiles:** temas principales, factores de riesgo, alertas agregadas por unidad, recomendaciones de acciones (no de sanciones).

El gran riesgo aquí es convertir un sistema de mejora organizativa en un sistema de vigilancia invasiva. Por eso conviene trabajar con datos agregados, minimizar la identificación individual y definir claramente finalidad y límites.

3.3 Formación y desarrollo (personalización de itinerarios)

La IA puede ayudar a personalizar formación: detectar brechas de habilidades, recomendar módulos por rol, crear planes de aprendizaje y medir progreso.

- **Inputs habituales:** rol, objetivos de negocio, evaluación de habilidades, historial de formación.

- **Outputs útiles:** itinerarios, recursos, ejercicios prácticos, evaluación de progreso.

Este dominio suele ser de **riesgo más bajo** y de alto valor, especialmente en pymes, porque se centra en mejorar capacidades sin afectar derechos en forma negativa.

4) Datos en RRHH: razonables vs sensibles (y por qué importa)

RRHH trabaja con datos personales casi por definición. Para diseñar casos con IA, el alumno debe dominar la diferencia entre:

- **Datos razonables para el caso** (mínimos necesarios): experiencia, habilidades declaradas, historial formativo, etapa del proceso, feedback estructurado.
- **Datos sensibles o de alto riesgo:** salud, afiliación, creencias, datos biométricos, orientación, información familiar, y en general cualquier dato que no sea imprescindible.

Además, existen datos que parecen “neutrales” pero actúan como **proxy**: código postal, universidad, edad aproximada, huecos laborales interpretados, nacionalidad, etc. Estas variables pueden correlacionar con características protegidas y generar discriminación indirecta.

Principios prácticos para alumnos:

1. **Minimización:** usa lo mínimo imprescindible.
2. **Finalidad:** define para qué se usa cada dato (y no lo uses para otra cosa).
3. **Transparencia:** si afecta a personas, debe poder explicarse qué se hace y con qué finalidad.
4. **Separación de funciones:** evita mezclar datos de desempeño con datos de salud o bienestar para decisiones individuales.

5) Sesgo y variables proxy: el riesgo central en selección y scoring

El sesgo en RRHH no suele ser intencional; aparece porque los datos históricos reflejan desigualdades previas o porque el modelo aprende patrones correlacionados con variables sensibles. Un ejemplo típico es que el histórico de “contratados exitosos” no represente a toda la población, y el sistema tienda a priorizar perfiles parecidos a los ya existentes, reduciendo diversidad.

Las **variables proxy** son especialmente peligrosas: aunque se elimine el género, el modelo puede inferirlo indirectamente por otras señales (ciertos centros educativos, interrupciones de carrera, tipo de actividades). Por eso, un control básico es auditar resultados por grupos y revisar variables y criterios, aunque sea de forma simple.

Controles mínimos recomendados (nivel empresa):

- criterios de selección explícitos (requisitos del puesto)
- uso de IA para estructurar, no para decidir automáticamente
- revisión humana obligatoria
- auditoría de resultados por subgrupos relevantes
- registro de criterios y versiones de prompts/modelos
- derecho a revisión y explicación interna

6) Interpretabilidad práctica: cómo explicar “por qué” sin matemáticas complejas

En RRHH, explicabilidad significa poder responder: ¿por qué este candidato fue priorizado o este caso fue marcado? La respuesta no puede ser “porque lo dijo el modelo”. Debe basarse en criterios comprensibles:

- “Cumple 4 de 5 requisitos del puesto, especialmente X y Y”.
- “Tiene evidencia de experiencia en Z y formación en A”.
- “Falta información en B, por eso se recomienda preguntar en entrevista”.

La forma más segura de lograr interpretabilidad práctica es exigir outputs estructurados: matrices de criterios, evidencias y preguntas sugeridas, en lugar de un “score” opaco. Esto convierte la IA en una herramienta que **documenta y hace trazable** la evaluación.

7) Medición: KPIs útiles y límites de lo medible

En RRHH, no todo se mide como en marketing. Aun así, es importante definir KPIs operativos y de calidad, y no caer en métricas que incentiven malas prácticas (por ejemplo, contratar rápido pero mal).

KPIs operativos (eficiencia):

- tiempo de cribado por candidatura
- tiempo total del proceso (time-to-hire)
- carga del equipo (nº candidatos revisados por semana)

KPIs de calidad (resultado):

- tasa de candidatos que avanzan y luego encajan (calidad de shortlist)
- satisfacción de hiring managers
- retención temprana (si se dispone)
- consistencia en evaluaciones (menos variabilidad entre evaluadores)

KPIs de equidad (control):

- distribución de shortlist por grupos relevantes (cuando sea legal y apropiado)
- revisión de disparidades en criterios o outcomes
- tasas de avance por segmentos

Límites: muchas veces no habrá datos perfectos; lo importante es declarar limitaciones y diseñar controles.

8) Operación segura: circuito de revisión humana, trazabilidad y gestión de incidentes

Un sistema de IA en RRHH debe incluir un circuito operativo claro:

1. **Entrada:** CVs/encuestas/formación, según caso.
2. **Procesamiento IA:** resumen estructurado, detección de temas, recomendación.
3. **Revisión humana:** validación y decisión final.
4. **Registro:** guardar evidencia de criterios y decisión (sin almacenar datos innecesarios).
5. **Monitorización:** revisar errores, sesgos potenciales y ajustes de prompts/plantillas.
6. **Incidentes:** procedimiento si hay un error grave (p. ej., discriminación o filtrado incorrecto).

Esta operación convierte el uso de IA en un proceso controlado en lugar de un “uso improvisado” que abre riesgos.

9) Herramientas y recursos útiles (orientado a un puesto junior)

El alumno debe conocer categorías de herramientas, más que “una marca”:

- **LLMs (asistencia):** ChatGPT / Claude / Gemini / Copilot
Usos: resúmenes estructurados, matrices de ajuste, preguntas de entrevista, redacción de comunicaciones internas. *Siempre con datos anonimizados o minimizados.*
- **ATS (reclutamiento):** sistemas de seguimiento de candidatos (según empresa) + funciones de filtrado/etiquetado.
- **Encuestas y clima:** herramientas de encuestas + análisis agregado (Dashboards).
- **Formación:** LMS corporativos + itinerarios (recomendaciones por rol).
- **Análítica y reporting:** Excel/Sheets, Power BI, Looker Studio.
- **Gobernanza documental:** plantillas de criterios, guías de entrevista, SOPs y registros (Notion/Drive/Confluence).

Nota práctica: en RRHH, el valor suele venir más de **estructurar criterios y evidencias** que de “automatizar decisiones”.

10) Mini-glosario

- **Screening:** cribado inicial de candidaturas.
- **Matching:** ajuste entre perfil y requisitos.
- **Proxy:** variable que correlaciona con una característica sensible.
- **Human-in-the-loop:** supervisión humana en decisiones.
- **Time-to-hire:** tiempo total para cubrir una vacante.
- **Shortlist:** lista corta de candidatos para entrevista.

Relación de ideas clave

- RRHH es un área de alto riesgo: la IA debe ser, por defecto, **asistente** y no juez.
- La diferencia asistencia vs decisión automática define el nivel de controles requeridos.
- Sesgos y proxies son el riesgo central en selección y scoring.
- Explicabilidad práctica = criterios + evidencias + outputs estructurados.
- Privacidad, minimización y finalidad son parte del diseño, no del final.

Más información en ChatGPT

1. “Dame 5 casos de uso de IA en RRHH de bajo riesgo y alto valor. Para cada uno: decisión, datos mínimos, KPI, riesgos y controles.”
2. “Convierte esta oferta de trabajo y este CV en una matriz de requisitos/evidencias, y sugiere preguntas de entrevista sin usar datos sensibles: [pegar texto].”
3. “Identifica posibles variables proxy y riesgos de sesgo en este proceso de selección: [descripción], y sugiere mitigaciones.”

FICHA 8.4 — IA en Finanzas: fraude/anomalías y scoring de riesgo (alertas, umbrales, coste del error y explicabilidad)

Referencia

- **Módulo:** 8. Aplicaciones de IA en áreas funcionales (12 h)
- **Apartado:** 8.4. IA en Finanzas
- **Capítulo:** 8.4.1–8.4.2

Palabras clave

detección de fraude, detección de anomalías, scoring de riesgo, crédito, impago, falsos positivos, falsos negativos, umbrales, alertas, revisión, coste del error, compliance, auditoría, explicabilidad, trazabilidad, monitorización, deriva, control de cambios, gobierno del modelo.

Objetivos de aprendizaje

Al finalizar esta ficha, deberás ser capaz de:

1. Diferenciar **fraude**, **anomalía** y **riesgo** (y entender por qué cada uno exige un enfoque operativo distinto).
2. Traducir un objetivo genérico (“usar IA en finanzas”) a **decisiones concretas** y a un circuito operativo: datos → alerta/score → revisión → decisión → registro.
3. Comprender el trade-off entre **falsos positivos y falsos negativos** y cómo se traduce en umbrales y costes (pérdida vs fricción).
4. Definir KPIs financieros/operativos adecuados (tasa de detección, tasa de confirmación, backlog, tiempo de resolución, coste evitado) y límites de lo medible.
5. Explicar por qué en finanzas son esenciales **explicabilidad, trazabilidad, documentación y control de cambios**, y proponer controles básicos.

Síntesis

En finanzas, la IA se utiliza principalmente para **detectar** (fraude/anomalías), **priorizar** (alertas) y **apoyar decisiones de riesgo** (scoring). El éxito no se mide por “precisión del modelo”, sino por la capacidad de integrarlo en un proceso de revisión y decisión con umbrales adecuados, explicaciones suficientes para auditoría y un registro completo de lo ocurrido. Sin circuito operativo, la IA genera ruido; con un circuito bien diseñado, reduce pérdidas y mejora eficiencia.

Contenido principal

1) Finanzas como disciplina de control: decisiones con coste del error

La función financiera y de control de una empresa se apoya en decisiones que tienen un rasgo común: el **coste del error** es alto y, muchas veces, asimétrico. Un falso negativo en fraude (no detectar una operación fraudulenta) puede significar pérdida directa y daño

reputacional. Un falso positivo (marcar como fraude algo legítimo) puede bloquear cobros, generar fricción con clientes o colapsar al equipo de revisión. Esta asimetría hace que la IA en finanzas se diseñe con un enfoque distinto al marketing: se privilegia **control, trazabilidad y explicabilidad** por encima de “experimentación rápida”.

En este contexto, lo más importante para dominar el tema no es aprender algoritmos, sino comprender cómo una predicción o un score se convierte en una decisión operativa. En finanzas, la IA suele funcionar como un **sistema de alerta y priorización**: genera señales para que un humano revise y decida. Cuando se automatiza, suele hacerse primero en acciones de bajo riesgo (por ejemplo, priorizar revisión), y solo más adelante en decisiones con impacto directo, siempre con controles estrictos.

2) Fraude, anomalía y riesgo: tres conceptos diferentes (y por qué importa distinguirlos)

2.1 Fraude

El fraude implica intención maliciosa o uso indebido: transacciones no autorizadas, suplantación, manipulación documental, etc. La detección de fraude se centra en identificar patrones sospechosos y, sobre todo, actuar rápidamente.

- **Objetivo:** minimizar pérdida y cortar el patrón.
- **Salida típica:** alerta de fraude + prioridad + razón.
- **Circuito:** bloquear, revisar, confirmar, escalar si procede.

2.2 Anomalía

Una anomalía es algo “fuera de lo normal”, pero no necesariamente fraude. Puede ser un error administrativo, un comportamiento legítimo excepcional o un síntoma temprano de problema.

- **Objetivo:** detectar desviaciones para investigar.
- **Salida típica:** alerta de anomalía + severidad + hipótesis de causa.
- **Circuito:** revisar, clasificar (error/legítimo/fraude), corregir datos o proceso.

2.3 Riesgo (scoring)

El scoring de riesgo estima probabilidad de eventos como impago, incumplimiento o “probabilidad de pérdida”. No busca detectar un caso puntual raro, sino apoyar decisiones recurrentes: conceder crédito, ajustar límites, priorizar cobro, etc.

- **Objetivo:** reducir riesgo total manteniendo negocio.
- **Salida típica:** score + segmento de riesgo (alto/medio/bajo) + explicación.
- **Circuito:** decisión con política (umbral), revisión de casos límite, registro.

Por qué esta distinción es crítica: porque define el tipo de datos, la latencia aceptable, el nivel de tolerancia a errores y el circuito operativo. Tratar anomalías como fraude crea fricción innecesaria; tratar fraude como anomalía puede causar pérdidas.

3) El patrón universal en finanzas: datos → score/alerta → revisión → decisión → registro

Casi cualquier aplicación de IA en finanzas que sea realista puede describirse como un flujo:

1. **Entrada (datos):** transacciones, facturas, pagos, historiales, comportamiento, documentos.
2. **Procesamiento (modelo/reglas):** detección o scoring.
3. **Salida (alerta/score):** un resultado que debe ser accionable: severidad, prioridad, razones.
4. **Revisión humana:** cola de trabajo con priorización (triage).
5. **Decisión:** aprobar, bloquear, pedir información, escalar, corregir.
6. **Registro y auditoría:** qué pasó, por qué se decidió, evidencias, versión del sistema.

Este patrón es esencial porque evita el error más común: quedarse en “un modelo que predice” sin un circuito que convierta predicción en acción y aprendizaje. El registro es especialmente importante porque permite revisar incidentes, responder auditorías y ajustar umbrales.

4) Falsos positivos y falsos negativos: el centro del diseño (no un detalle técnico)

En proyectos de detección, el rendimiento del sistema se entiende mejor con dos errores:

- **Falso positivo (FP):** alerta sobre algo que era legítimo.
- **Falso negativo (FN):** no alertar sobre algo que era problemático.

En finanzas, estos errores tienen costes muy diferentes. Un FN en fraude suele ser más caro que un FP, pero un exceso de FPs puede colapsar al equipo y generar “fatiga de alertas”. Por eso, el objetivo real es encontrar un **umbral operativo** que equilibre pérdidas evitadas y carga de revisión.

Para dominar este tema, debes aprender a traducirlo en preguntas operativas:

- ¿Cuántas alertas al día puede revisar el equipo sin degradar tiempos?
- ¿Cuál es el coste medio de un fraude no detectado?
- ¿Cuál es el coste de bloquear una operación legítima? (reclamación, churn, reputación)
- ¿Qué casos requieren bloqueo inmediato y cuáles solo revisión?

La respuesta define umbrales distintos para diferentes tipos de operación. Muchas organizaciones usan modelos con “severidad” (alto/medio/bajo) y aplican políticas diferentes: los de alta severidad pueden bloquear temporalmente; los de severidad media van a revisión; los bajos se registran y se muestrean.

5) Datos mínimos y calidad: por qué el dato “manda” más que el algoritmo

La IA en finanzas depende de datos precisos y trazables. No es lo mismo analizar transacciones (datos estructurados) que documentos (facturas, justificantes) o comunicaciones (emails). Para cada caso hay un conjunto de datos mínimos:

Para fraude/anomalías en transacciones:

- importe, fecha/hora, canal, ubicación (si aplica y es legítimo), método de pago
- identificadores de cuenta/cliente (con cuidado y minimización)
- histórico de transacciones, patrones habituales
- estado de confirmación (fraude confirmado, legítimo, error)

Para scoring de riesgo:

- histórico de pagos/cobros, retrasos, incumplimientos
- límites, exposición, comportamiento de pago
- variables de negocio relacionadas (sector, tamaño) *si son permitidas y relevantes*
- outcomes: impago/no impago, recuperación, etc.

Errores típicos de datos:

- duplicados, campos nulos, estados inconsistentes
- falta de etiqueta de "caso confirmado" (sin verdad terreno no se aprende)
- cambios de proceso no documentados (rompen comparaciones históricas)
- sesgos históricos (por ejemplo, solo se investigan ciertos casos)

Una idea importante: en detección de fraude, el "ground truth" (qué era fraude realmente) no siempre está disponible de inmediato. Puede tardar semanas en confirmarse. Por tanto, el sistema debe diseñarse con esa realidad: registro, revisiones y actualización posterior.

6) Umbrales, colas y priorización: cómo la IA se vuelve operable

El resultado de un modelo debe integrarse en una cola de revisión. En finanzas, la cola y la priorización son tan importantes como el score.

Elementos operativos mínimos:

1. **Severidad/prioridad:** alto/medio/bajo.
2. **Razones:** 2-5 señales que justifican la alerta.
3. **Acción sugerida:** bloquear temporalmente, pedir info, revisar manualmente, escalar.
4. **SLA:** cuánto tiempo puede tardar la revisión.
5. **Registro:** quién revisó, qué decidió, qué evidencia consultó.

La IA debe ayudar a "triage": decidir qué revisar primero. Si el sistema solo genera alertas sin priorizar, el equipo se bloquea. Si prioriza bien, el equipo revisa menos casos para evitar más pérdida.

7) Métricas en finanzas: medir valor y fricción (no solo precisión)

En proyectos aplicados, se recomienda medir cuatro dimensiones:

a) Eficacia (detección/valor)

- tasa de confirmación (qué % de alertas eran reales)
- valor monetario evitado (estimación)
- reducción de pérdidas / recuperación

b) Eficiencia operativa

- nº alertas/día
- tiempo medio de revisión
- backlog pendiente
- ratio de escalado a segundo nivel

c) Falsos positivos y fricción

- % de operaciones legítimas bloqueadas

- reclamaciones o incidencias por bloqueo
- impacto en experiencia de cliente/usuario

d) Cumplimiento y trazabilidad

- % de casos con registro completo
- % de decisiones con razón documentada
- tiempo de respuesta ante auditoría/incidente

El objetivo real suele ser optimizar un balance: evitar pérdidas sin crear fricción excesiva ni colapsar operación.

8) Explicabilidad y auditoría: el requisito diferencial en finanzas

En finanzas, la explicabilidad no es un lujo; es un requisito práctico. Debes poder responder: “¿por qué se bloqueó este pago?”, “¿por qué se priorizó este caso?”, “¿por qué se dio este score?”. Esto no exige necesariamente modelos complejos de interpretabilidad matemática; exige **explicabilidad operativa**, basada en señales y reglas comprensibles.

Explicabilidad operativa mínima incluye:

- las señales principales (top factores) que llevaron al resultado
- umbral aplicado (qué regla de decisión se usó)
- versión del modelo/reglas/prompt
- evidencia consultada por el revisor humano
- decisión final y responsable

Un error frecuente es usar scores “misteriosos” sin razones. Eso puede funcionar en un piloto, pero se rompe cuando hay una disputa, un incidente o una auditoría. Por ello, se recomienda diseñar outputs que incluyan “razones” y “nivel de confianza” o “severidad”.

9) Riesgos y controles: seguridad, sesgo, privacidad y control de cambios

En finanzas, los riesgos se agrupan en cuatro categorías:

- 1) Riesgo de calidad:** alertas mal calibradas, deriva, cambios de comportamiento.
- 2) Riesgo de seguridad:** manipulación, intentos de evadir detección, ataques a sistemas.
- 3) Riesgo de privacidad:** uso indebido de datos personales o retención excesiva.
- 4) Riesgo de gobernanza:** cambios no controlados, ausencia de owner, falta de registro.

Controles mínimos recomendados:

- revisión humana para acciones críticas
- control de cambios (versionado y changelog)
- umbrales revisados periódicamente
- auditorías internas por muestras
- políticas de datos (minimización, retención, acceso)
- plan de incidentes (qué hacer si se bloquea masivamente por error)

10) Herramientas y recursos útiles (orientado a un puesto junior)

En puestos junior, muchas tareas se relacionan con calidad de datos, reporting y operación:

- **Hojas de cálculo + BI:** Excel/Sheets, Power BI, Looker Studio (reporting de alertas, tendencias, backlog).
- **Sistemas financieros/ERP:** según empresa (SAP, Dynamics, Odoo, etc.).
- **Herramientas antifraude / pagos:** dependen del sector (pasarelas con módulos antifraude).
- **Gestión de casos:** ticketing o herramientas internas para colas de revisión.
- **LLMs (apoyo documental):** ChatGPT/Claude/Gemini para redactar procedimientos, checklists, plantillas de registro y documentación (nunca con datos sensibles sin anonimizar).

Recomendación práctica: aunque la empresa tenga herramientas avanzadas, tu valor como junior crece si dominas el circuito operativo y puedes explicar KPIs, umbrales y evidencias.

II) Mini-glosario

- **Fraude:** actividad intencional maliciosa.
- **Anomalía:** desviación de patrón normal (no siempre fraude).
- **Scoring:** puntuación de riesgo o probabilidad.
- **Falso positivo/negativo:** errores de detección.
- **Umbral:** punto a partir del cual se dispara acción o revisión.
- **Backlog:** casos pendientes en cola de revisión.
- **Explicabilidad operativa:** razones comprensibles y trazables del resultado.

Relación de ideas clave

- Fraude, anomalía y riesgo no son lo mismo; cambian circuito y controles.
- El valor de la IA aparece cuando se integra en colas de revisión con umbrales y registro.
- El trade-off FP/FN define el diseño operativo y el umbral.
- En finanzas, explicabilidad, trazabilidad y control de cambios son imprescindibles.
- Medir valor implica balancear pérdidas evitadas y fricción operativa.

Más información en ChatGPT

1. "Diseña un flujo operativo de detección de fraude: datos mínimos, severidad, umbrales, revisión humana, KPIs y registro."
2. "Explicame cómo elegir un umbral cuando mi equipo solo puede revisar 50 alertas/día, y qué métricas usar para calibrarlo."
3. "Ayúdame a redactar un apartado de explicabilidad y auditoría para un sistema de scoring de riesgo, con evidencias y control de cambios."

FICHA 8.5 — IA en Operaciones y Producción: control de calidad con datos e imágenes (defectos, severidad, decisiones y errores)

Referencia

- **Módulo:** 8. Aplicaciones de IA en áreas funcionales (12 h)
- **Apartado:** 8.5. IA en Operaciones y Producción
- **Capítulo:** 8.5.1

Palabras clave

control de calidad, inspección, visión por computador, defectos, severidad, criterio de aceptación, muestreo, falsos rechazos, falsas aceptaciones, trazabilidad, SPC, scrap, rework, OEE, deriva, calibración, iluminación, tolerancias, auditoría.

Objetivos de aprendizaje

Al finalizar esta ficha, deberás ser capaz de:

1. Definir qué es un **defecto** y qué es la **severidad** del defecto, y por qué son el corazón del control de calidad.
2. Comprender el impacto de los dos errores críticos: **falso rechazo** (rechazar correcto) y **falsa aceptación** (aceptar defectuoso), y cómo determinan umbrales.
3. Traducir “usar IA en calidad” a decisiones operativas concretas: **aceptar / rechazar / revisar**, con un circuito y responsables definidos.
4. Identificar los datos mínimos y condiciones de operación que condicionan el éxito (captura, iluminación, variabilidad, cambios de proceso).
5. Diseñar controles básicos: revisión humana, muestreo, trazabilidad, monitorización y control de cambios.

Síntesis

En operaciones, la IA para control de calidad no consiste solo en “reconocer defectos”, sino en diseñar un sistema que tome decisiones repetibles: **qué se considera defecto, con qué severidad, qué acción corresponde y cómo se registra**. La calidad exige trazabilidad, control de errores y gestión de condiciones reales (materiales, iluminación, cambios en la línea). Un modelo puede ser “bueno” en laboratorio y fallar en planta si no se define el proceso operativo completo.

Contenido principal

1) Control de calidad como sistema de decisión: de “ver” a “actuar”

El control de calidad es una función de decisión: determina si una pieza, lote o proceso cumple un estándar. Cuando se incorpora IA (por ejemplo visión por computador), el objetivo no es impresionar con tecnología, sino reducir variabilidad, acelerar inspección y disminuir errores humanos, manteniendo o mejorando el nivel de calidad. Para que esto

sea posible, hay que entender que la IA no sustituye a la definición del estándar: la empresa debe definir qué es aceptable, qué no lo es y cómo actuar cuando hay incertidumbre.

Por eso, un proyecto de IA en calidad se formula mejor como un circuito operativo: una entrada (pieza o imagen), un análisis (detectar/medir), una decisión (aceptar/rechazar/revisar), una acción (apartar, reprocesar, parar línea) y un registro (trazabilidad). Si falta cualquiera de estos elementos, la implantación se vuelve frágil, porque nadie puede demostrar qué pasó ni mejorar el sistema.

2) Defecto y severidad: el vocabulario que manda todo el diseño

Un **defecto** es una desviación respecto a especificación. Puede ser dimensional (tamaño), superficial (arañazo), funcional (no encaja), estético (marca) o de integridad (fisura). La **severidad** define el impacto del defecto y, por tanto, la acción. No todos los defectos son iguales: algunos son críticos (seguridad), otros mayores (función), otros menores (estética).

En control de calidad, la severidad suele clasificarse en niveles (por ejemplo: crítico / mayor / menor), y cada nivel implica una regla: parar línea, rechazar, reprocesar, o aceptar con observación. En IA, esta clasificación se traduce en dos cosas: (1) qué defectos se etiquetan y entrenan, y (2) qué umbrales de decisión se aplican. Si no se define severidad con claridad, el sistema se vuelve incoherente: el mismo defecto puede acabar aceptándose un día y rechazándose otro.

Recomendación operativa: antes de hablar de modelos, define una “tabla de defectos” con:

- Nombre del defecto
- Descripción visual/medible
- Severidad
- Acción (aceptar/rechazar/revisar)
- Evidencia requerida (foto, medida, lote)
- Responsable de la decisión final

3) Los dos errores clave: falso rechazo y falsa aceptación (y por qué importan más que la precisión)

En inspección automatizada, el rendimiento del sistema suele expresarse como “acierta/no acierta”, pero en planta lo que importa es el coste de dos errores:

- **Falso rechazo (FR):** rechazar una pieza correcta. Impacto: scrap innecesario, reprocesos, coste, retrasos.
- **Falsa aceptación (FA):** aceptar una pieza defectuosa. Impacto: devoluciones, fallos en cliente, riesgos de seguridad, reputación, posibles paradas aguas abajo.

Estos errores no valen lo mismo. En sectores críticos (automoción, aero, salud), una falsa aceptación puede ser muchísimo más costosa que un falso rechazo, lo que empuja a umbrales conservadores. En otros contextos (productos de bajo coste), un falso rechazo

masivo puede ser inasumible. Por tanto, el sistema debe definirse según la política de calidad del negocio: cuál es el coste tolerable.

Consecuencia práctica: el umbral de decisión no se elige por estética ni por “precisión global”; se elige por el equilibrio entre FR y FA, y por la capacidad de la operación para revisar excepciones.

4) El patrón operativo “ACEPTAR / RECHAZAR / REVISAR”

Para que la IA sea implementable, el diseño más realista suele tener tres salidas:

1. **Aceptar:** el sistema está muy seguro de que cumple.
2. **Rechazar:** el sistema está muy seguro de que no cumple.
3. **Revisar:** el sistema detecta duda, o el coste del error es alto, o el caso es raro.

Este patrón es fundamental porque reconoce que siempre habrá incertidumbre (variabilidad de piezas, cambios de luz, defectos nuevos). Además, convierte la IA en una herramienta que reduce carga humana, sin eliminar control humano donde es necesario.

Para operar este patrón necesitas:

- un **umbral de aceptación**
- un **umbral de rechazo**
- una banda intermedia (zona gris) que va a revisión
- un circuito de revisión con tiempos, responsables y registro

5) Datos mínimos y condiciones de captura: por qué “la cámara manda”

En visión por computador y en inspección con sensores, la calidad de la captura determina el techo del sistema. La IA puede compensar algunas variaciones, pero no puede inventar información que no se ve. Por eso el diseño debe incluir consideraciones de captura:

- **Iluminación:** estabilidad, sombras, reflejos, temperatura de color.
- **Posicionamiento:** distancia, ángulo, repetibilidad.
- **Fondo y contraste:** separar pieza/defecto del entorno.
- **Variabilidad del producto:** lotes, proveedores, materiales, acabados.
- **Velocidad de línea:** motion blur, tiempos de exposición.

Además de imagen, hay casos donde el control de calidad usa datos de sensores (peso, temperatura, presión) o datos de proceso (parámetros de máquina). En esos casos, la IA funciona mejor si:

- el dato está calibrado
- hay trazabilidad por lote/tiempo
- se conocen rangos normales y excepciones

Errores típicos que rompen el sistema:

- cambios de iluminación o cámara sin registrar
- nuevos materiales sin incluir en el dataset
- cambios de tolerancia sin actualizar criterios
- “parches” de proceso que alteran la apariencia del producto

6) Etiquetado, muestreo y verdad terreno: cómo construir evidencia en calidad

Para que un sistema de IA sea fiable, necesita ejemplos etiquetados (qué era defecto y cuál). En la práctica industrial, el etiquetado perfecto no existe; pero debe existir un proceso de verdad terreno:

- muestreo de piezas para revisión experta
- registro de decisiones (por qué se rechazó)
- trazabilidad del lote y parámetros asociados
- almacenamiento de ejemplos representativos (típicos y raros)

Esto es clave por dos motivos: primero, permite mejorar el sistema cuando falla; segundo, permite auditar y defender decisiones ante cliente o proveedor.

7) Métricas útiles (más allá de “acierto”)

En planta, la medición debe combinar calidad y operación:

KPIs de calidad:

- tasa de defectos por tipo
- scrap y rework
- devoluciones/quejas (si aplica)
- capacidad de detección por severidad

KPIs operativos del sistema:

- % de casos en “revisar” (carga humana residual)
- tiempo medio de inspección
- backlog de revisión
- estabilidad por turno/lote

KPIs de negocio:

- coste evitado por reducción de devoluciones
- reducción de reprocesos
- mejora de OEE si reduce paradas por calidad

8) Riesgos y controles: deriva, cambios de proceso y gobernanza mínima

El principal enemigo en operaciones es el cambio: cambia el proveedor, cambia el material, cambia la luz, cambia la velocidad de línea. Ese cambio produce **deriva**: el sistema deja de comportarse como antes.

Controles mínimos recomendados:

- **Control de cambios:** registrar cualquier cambio en captura/proceso.
- **Monitorización:** alertas cuando sube “revisar” o cuando cambian tasas de defecto de forma anómala.
- **Revisión humana estructurada:** muestreo periódico aunque “todo vaya bien”.
- **Changelog y versionado:** qué versión del criterio/modelo se aplicó a cada lote.
- **Plan de incidentes:** qué hacer si el sistema empieza a rechazar demasiado o deja pasar defectos.

9) Herramientas y recursos útiles (orientado a puesto junior)

En un rol junior, tu impacto suele estar en documentación, control del proceso y reporting:

- **Hojas de cálculo y BI:** Excel/Sheets, Power BI/Looker para KPIs de calidad y revisión.
- **Sistemas de calidad:** QMS/ERP (según empresa) para trazabilidad de lotes y no conformidades.
- **Captura/etiquetado:** herramientas internas o plataformas de anotación (según entorno).
- **IA/LLMs (apoyo):** para redactar procedimientos (SOP), checklists de defectos y reportes ejecutivos; siempre sin datos sensibles.

Consejo: en calidad, “dominar IA” significa poder explicar criterios, umbrales y evidencias, no solo hablar de modelos.

10) Mini-glosario

- **Defecto:** desviación de especificación.
- **Severidad:** impacto del defecto (crítico/mayor/menor).
- **Falso rechazo / falsa aceptación:** errores de decisión.
- **Zona gris:** casos que van a revisión.
- **Deriva:** cambio en condiciones que reduce rendimiento.
- **Trazabilidad:** capacidad de reconstruir qué pasó y por qué.

Relación de ideas clave

- La IA en calidad es un sistema: detectar → decidir → actuar → registrar.
- Defecto y severidad definen umbrales y acciones.
- FR y FA importan más que “precisión” abstracta.
- El patrón aceptar/rechazar/revisar hace el sistema operable.
- Cambios de proceso y deriva exigen control de cambios y monitorización.

Más información en ChatGPT

1. “Ayúdame a definir una tabla de defectos y severidad para un producto [X], con acciones y evidencias.”
2. “Diseña un circuito operativo aceptar/rechazar/revisar con umbrales y responsables para una inspección de calidad.”
3. “Propón KPIs y un plan de monitorización para detectar deriva en un sistema de inspección.”

FICHA 8.6 — IA en Operaciones y Producción: optimización de procesos y robótica colaborativa (cuellos de botella, restricciones y seguridad humano-robot)

Referencia

- **Módulo:** 8. Aplicaciones de IA en áreas funcionales (12 h)
- **Apartado:** 8.5. IA en Operaciones y Producción

- **Capítulo:** 8.5.2

Palabras clave

optimización de procesos, cuellos de botella, throughput, tiempos de ciclo, teoría de restricciones, OEE, balanceo de línea, simulación, planificación, programación, robótica colaborativa, cobots, seguridad industrial, ergonomía, SOP, excepciones, mantenimiento, ROI industrial.

Objetivos de aprendizaje

Al finalizar esta ficha, deberás ser capaz de:

1. Identificar un proceso como un flujo medible (tiempos, colas, variabilidad) y localizar el **cuello de botella**.
2. Diferenciar optimización “local” (mejorar una parte) de optimización “global” (mejorar el sistema completo).
3. Definir KPIs operativos de producción (tiempo de ciclo, throughput, WIP, OEE, scrap/rework) y medir antes/después.
4. Entender qué tareas son candidatas a **robótica colaborativa** y qué condiciones de seguridad y operación deben cumplirse.
5. Proponer un plan por fases (piloto → estabilización → escalado) con ownership, SOP y control de excepciones.

Síntesis

Optimizar operaciones no consiste en “meter IA en todo”, sino en entender restricciones: el rendimiento de un sistema lo marca el cuello de botella y la variabilidad. La IA puede ayudar a planificar, priorizar, reducir tiempos, detectar anomalías y soportar decisiones. La robótica colaborativa aporta valor cuando automatiza tareas repetitivas o ergonómicamente costosas con seguridad, SOP y mantenimiento. En ambos casos, el éxito depende del diseño operativo: objetivos claros, medición, excepciones y gobernanza.

Contenido principal

1) Optimización de procesos: pensar en sistema, no en piezas sueltas

En producción, una tentación habitual es optimizar “lo que se ve”: una estación lenta, una tarea manual, un turno con más incidencias. Sin embargo, un proceso industrial es un sistema con restricciones: si mejoras una parte que no es limitante, el rendimiento global puede no cambiar. Por eso, el primer principio para dominar optimización es entender que el sistema se comporta como una cadena: el eslabón más débil marca el ritmo. La IA y la analítica aportan valor si ayudan a identificar dónde se pierde rendimiento y qué intervención cambia el throughput. Esto puede incluir desde detectar patrones de paradas, hasta ajustar programación o proponer redistribución de carga. Pero siempre debe estar conectado a un KPI y a una restricción: “mejoro X, porque el cuello de botella está en Y”.

2) Vocabulario operativo: throughput, tiempo de ciclo, WIP y variabilidad

Para hablar con rigor, necesitas cuatro conceptos:

- **Tiempo de ciclo:** tiempo que tarda una unidad en completarse en una estación o proceso.
- **Throughput:** unidades completadas por unidad de tiempo (salida real del sistema).
- **WIP (Work In Progress):** trabajo en curso (inventario en proceso).
- **Variabilidad:** fluctuación en tiempos y calidad, que genera colas e ineficiencia.

Estos conceptos están ligados: variabilidad aumenta WIP y colas; colas aumentan tiempos; y el throughput lo define el paso más lento y más variable.

3) Identificación del cuello de botella (la habilidad clave)

El cuello de botella es el recurso que limita el throughput del sistema. No siempre es el más lento “en promedio”; puede ser el que tiene más paradas, más cambios de formato o más variabilidad.

Métodos prácticos para detectarlo:

1. **Datos:** mirar dónde se acumulan colas o WIP, dónde hay más paradas, dónde el tiempo de ciclo es más alto o más variable.
2. **Observación:** mapear el proceso y observar durante un turno: ¿dónde espera el material? ¿dónde se “atasca”?
3. **Indicadores:** si una estación está siempre ocupada y las demás tienen tiempos muertos, suele ser candidata a cuello.

Una vez identificado, la regla de oro es: la prioridad de mejora se enfoca primero en el cuello, porque es donde un minuto ahorrado puede convertirse en más throughput real.

4) Optimización bajo restricciones: mejorar sin romper la operación

Optimizar procesos requiere respetar restricciones reales:

- seguridad y normativa
- calidad y tolerancias
- disponibilidad de personal
- mantenimiento de máquinas
- capacidad de buffers y logística interna
- ventanas de entrega y prioridades

Por eso, los proyectos de IA en operaciones no se formulan como “minimizar tiempos” sino como “maximizar throughput y calidad dentro de restricciones, minimizando coste y variabilidad”. En la práctica, se empieza por intervenciones de bajo riesgo: estandarizar procedimientos, mejorar planificación, reducir cambios, mejorar mantenimiento preventivo, o apoyar al operario con checklists y avisos.

5) Casos típicos donde la IA aporta valor en optimización

Sin entrar en algoritmos, conviene conocer los “familiares” de casos de uso:

1. **Priorización y programación:** decidir qué órdenes se ejecutan primero según prioridad, disponibilidad y cambios.
2. **Detección de anomalías de proceso:** detectar desviaciones tempranas en parámetros de máquina.
3. **Predicción de tiempos y ETA internos:** estimar cuándo estará listo un lote o una orden.
4. **Optimización de recursos:** balanceo entre líneas o turnos, asignación de tareas.
5. **Soporte a decisiones:** recomendaciones “si pasa X, hacer Y” basadas en histórico.

La clave es que cada caso debe terminar en una acción: replanificar, ajustar, intervenir o redistribuir.

6) Métricas de operación: cómo medir mejora sin autoengañarse

Una intervención debe mostrar mejora en KPIs del sistema. Los más habituales:

- **Throughput** (unidades/hora)
- **Tiempo de ciclo y tiempo de espera**
- **OEE** (visión general: disponibilidad × rendimiento × calidad)
- **Scrap y rework**
- **Paradas no planificadas** y su duración
- **WIP** y tiempos de cola

Además, es importante medir antes/después en condiciones comparables (turnos similares, mix de productos similar). En operaciones, la estacionalidad y el mix de producto pueden cambiar más que la intervención, por lo que conviene documentar supuestos.

7) Robótica colaborativa (cobots): qué es y cuándo encaja

Los cobots están diseñados para compartir espacio con humanos con medidas de seguridad. Su valor aparece cuando se eligen tareas adecuadas:

Buenas candidatas:

- tareas repetitivas y de baja variabilidad
- manipulación y pick&place
- atornillado, pegado, empaquetado
- carga/descarga de estaciones
- tareas ergonómicamente costosas

Malas candidatas (sin rediseño):

- tareas con alta variabilidad de piezas sin guiado
- entornos con cambios constantes
- tareas que requieren juicio humano fino sin sensores adecuados

El éxito con cobots requiere un análisis de variabilidad: cuanto más estandarizada sea la pieza y el proceso, más viable es automatizar.

8) Seguridad humano-robot y operación: lo que hace viable el despliegue

La robótica no es solo “poner un brazo”. Requiere:

- evaluación de riesgos y normas de seguridad aplicables
- definición de zonas, velocidades y paradas de emergencia
- SOP de operación (inicio, parada, incidencias)
- formación del personal
- mantenimiento preventivo y responsable (owner)

Además, debe definirse cómo se gestionan excepciones: pieza mal colocada, fallo de agarre, cambio de lote, reinicio tras parada.

En proyectos reales, uno de los mayores riesgos es que el cobot sea técnicamente viable, pero operativamente inviable por falta de SOP, mantenimiento y ownership.

9) Integración IA + robótica: dónde se complementan

IA y robótica se complementan cuando:

- visión por computador guía el posicionamiento o inspección
- detección de anomalías anticipa mantenimiento
- programación y optimización deciden secuencias de trabajo
- asistentes (LLM) documentan incidencias y guían procedimientos (con cuidado)

No se trata de “poner IA al cobot”, sino de diseñar un sistema donde sensores, reglas y personas colaboran.

10) Plan por fases: piloto → estabilización → escalado

Un plan realista para optimización o robótica suele seguir:

1. **Piloto controlado:** una estación, un turno, un tipo de producto. Medición intensa.
2. **Estabilización:** mejorar SOP, reducir excepciones, formar, fijar métricas.
3. **Escalado:** ampliar a más productos/turnos, integrar con sistemas, formalizar mantenimiento.

En cada fase hay que definir: responsable (owner), KPI de éxito, riesgos, y qué se registra.

11) Herramientas y recursos útiles (orientado a puesto junior)

- **Mapeo y mejora:** VSM (Value Stream Mapping), diagramas de proceso, hojas de tiempos.
- **BI y análisis:** Excel/Sheets, Power BI/Looker para OEE, scrap, paradas y throughput.
- **Sistemas industriales:** MES/ERP (según empresa) para órdenes y datos de producción.
- **Gestión de mantenimiento:** CMMS para intervenciones, repuestos y tiempos.
- **IA/LLMs (apoyo):** redactar SOPs, checklists, reportes de incidencias; siempre sin datos sensibles y sin sustituir decisiones de seguridad.

12) Mini-glosario

- **Cuello de botella:** recurso que limita throughput.
- **Throughput:** salida real por tiempo.
- **WIP:** trabajo en curso.
- **OEE:** indicador global de eficiencia.

- **Cobot:** robot colaborativo con medidas de seguridad.
- **SOP:** procedimiento operativo estándar.

Relación de ideas clave

- Optimizar es mejorar el sistema, no solo una estación.
- El cuello de botella y la variabilidad explican gran parte del rendimiento.
- Métricas antes/después deben ser comparables.
- Cobots aportan valor en tareas repetitivas y estandarizadas, con seguridad y SOP.
- Escalar requiere ownership, mantenimiento, control de excepciones y registro.

Más información en ChatGPT

1. “Con este proceso [descripción], identifica el cuello de botella y propone 5 mejoras con KPIs y riesgos.”
2. “Dime qué tareas son buenas candidatas para un cobot en [industria] y qué controles de seguridad y SOP serían necesarios.”
3. “Ayúdame a definir un plan por fases (piloto–estabilización–escalado) para una mejora operativa con métricas y responsables.”